



Facultad de Ingeniería Mecánica y Eléctrica

Universidad Autónoma de Nuevo León

Introduccion al Aprendizaje Maquina

Análisis Exploratorio y Preprocesamiento de datos

Actividad Fundamental 1

Fecha: 13/11/2026

Profesor: Daniel Isaias López Paez

Hora: V1 - V2

Integrantes

Nombre	**Matrícula**
Vanessa Rodriguez Colunga	2158341
Sergio Jaziel Butzmann Martinez	2163239
Gustavo Guzman Puente	2060982
Diego Alonso Carrillo Castillo	2144556
Uriel Samuel Bravo Castillo	2227015

Índice

1. Introducción **3**

2. Objetivo **3**

3. Marco Teórico **3**
3.1. Análisis Exploratorio de Datos . . . 3
3.2. Tratamiento de valores nulos . . . 3
3.3. Detección de valores atípicos mediante el IQR . . . 3
3.4. Codificación de variables categóricas . . . 4
3.5. Desbalance de clases . . . 4

4. Materiales y Herramientas **4**

5. Desarrollo **5**
5.1. Carga e inspección inicial . . . 5
5.2. Limpieza y transformación . . . 6
5.3. Análisis visual . . . 7

6. Resultados y Análisis **8**

7. Conclusiones **9**

1. Introducción

El Análisis Exploratorio de Datos (EDA) es la etapa inicial de cualquier proyecto de aprendizaje automático, en la que se inspecciona, limpia y visualiza un conjunto de datos antes de modelarlo. En esta actividad se trabajó con el *Stroke Prediction Dataset*, disponible en Kaggle [1], que contiene 5110 registros de pacientes con variables fisiológicas y de estilo de vida, y cuyo propósito es predecir el riesgo de sufrir un accidente cerebrovascular. Utilizando Python en Google Colab, junto con las bibliotecas pandas, NumPy y Matplotlib, se realizó la carga e inspección de los datos, su limpieza y transformación, y un análisis visual para identificar los factores de riesgo más relevantes.

2. Objetivo

Desarrollar habilidades prácticas en la carga, inspección, visualización y limpieza de un conjunto de datos real mediante Python en Google Colab, con el fin de identificar problemas de calidad en los datos, preparar el conjunto para su modelado y extraer patrones visuales de su comportamiento en relación con la variable objetivo `stroke`.

3. Marco Teórico

3.1. Análisis Exploratorio de Datos

El EDA consiste en examinar un conjunto de datos mediante resúmenes numéricos y gráficas para conocer su estructura, detectar anomalías y formular hipótesis antes de aplicar cualquier modelo [5]. En Python, esta tarea se apoya en pandas para el manejo de tablas [4], NumPy para el cálculo numérico [2] y Matplotlib para la visualización [3].

3.2. Tratamiento de valores nulos

Cuando una variable tiene datos faltantes, una estrategia común es la imputación, que consiste en rellenarlos con un valor representativo. La mediana es preferible a la media cuando la variable presenta valores extremos, ya que no se ve arrastrada por ellos.

3.3. Detección de valores atípicos mediante el IQR

El rango intercuartílico se define como la distancia entre el tercer y el primer cuartil, y representa el ancho del 50 % central de los datos. Un valor se considera atípico si queda fuera de los siguientes límites [5]:

$$IQR = Q_3 - Q_1, \qquad L_{inf} = Q_1 - 1.5\,IQR, \qquad L_{sup} = Q_3 + 1.5\,IQR \tag{1}$$

Un valor atípico es un dato inusual respecto al resto, no necesariamente un error de captura.

3.4. Codificación de variables categóricas

Los algoritmos de aprendizaje automático operan con números, por lo que las variables de texto deben convertirse. La codificación *One-Hot* crea una columna binaria por cada categoría, con valor 1 si el registro pertenece a ella y 0 en caso contrario.

3.5. Desbalance de clases

Existe desbalance de clases cuando una categoría de la variable objetivo tiene muchos más registros que la otra. En ese caso, un modelo puede alcanzar una exactitud alta prediciendo siempre la clase mayoritaria sin detectar los casos de interés.

4. Materiales y Herramientas

- **Python 3:** lenguaje de programación utilizado para todo el análisis.
- **Google Colab:** entorno de ejecución del notebook.
- **pandas:** carga, inspección, limpieza y codificación de los datos.
- **NumPy:** cálculo de cuartiles y límites del IQR.
- **Matplotlib:** generación de gráficas de barras, histogramas y dispersión.
- **Stroke Prediction Dataset:** archivo `healthcare-dataset-stroke-data.csv`, con 5110 registros y 12 columnas [1].
- **GitHub:** repositorio donde se aloja el notebook de la actividad.

Tabla 1: Variables del conjunto de datos

Variable	Tipo	Descripción
`id`	Numérica	Identificador del paciente
`gender`	Texto	Género
`age`	Numérica	Edad
`hypertension`	Binaria	1 si tiene hipertensión
`heart_disease`	Binaria	1 si tiene enfermedad cardíaca
`ever_married`	Texto	Si ha estado casado/a
`work_type`	Texto	Tipo de trabajo
`Residence_type`	Texto	Zona urbana o rural
`avg_glucose_level`	Numérica	Glucosa promedio en sangre
`bmi`	Numérica	Índice de masa corporal
`smoking_status`	Texto	Hábito de fumar
`stroke`	Binaria	Variable objetivo (1 = derrame)

5. Desarrollo

El notebook completo de la actividad se encuentra en el siguiente repositorio:
https://github.com/vanessardz-1203/IML

5.1. Carga e inspección inicial

Se importaron las bibliotecas y se cargó el archivo CSV en un DataFrame de pandas. Después se revisaron las primeras y últimas cinco filas, la estructura general y las estadísticas descriptivas de las variables numéricas.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

df = pd.read_csv("healthcare-dataset-stroke-data.csv")
print(df.shape)
display(df.head())
display(df.tail())
df.info()
display(df.describe())
display(df.isnull().sum())
```

Listing 1: Carga e inspeccion inicial

El conjunto contiene 5110 registros y 12 columnas. Al revisar los valores faltantes, únicamente la variable `bmi` presentó datos nulos, con 201 registros (alrededor del 3.9 %); el resto de las columnas estaba completo.

	0
id	0
gender	0
age	0
hypertension	0
heart_disease	0
ever_married	0
work_type	0
Residence_type	0
avg_glucose_level	0
bmi	201
smoking_status	0
stroke	0

Figura 1: Conteo de valores nulos por columna

5.2. Limpieza y transformación

Imputación de `bmi`. Los 201 valores faltantes se rellenaron con la mediana de la columna, por ser robusta ante valores extremos.

Valores atípicos de glucosa. Se calcularon los cuartiles con NumPy y los límites del IQR para `avg_glucose_level`.

```
mediana_bmi = df["bmi"].median()
df["bmi"] = df["bmi"].fillna(mediana_bmi)

glu = df["avg_glucose_level"]
q1 = np.percentile(glu, 25)
q3 = np.percentile(glu, 75)
iqr = q3 - q1
lim_inf = q1 - 1.5 * iqr
lim_sup = q3 + 1.5 * iqr
outliers = df[(glu < lim_inf) | (glu > lim_sup)]
```

Listing 2: Imputacion de bmi y deteccion de outliers

Tabla 2: Resultados del método IQR para la glucosa

Medida	**Valor**
Q_1	77.245
Q_3	114.09
IQR	36.845
Límite inferior	21.98
Límite superior	169.36
Outliers detectados	627 (12.3 %)

Los 627 valores atípicos se encuentran todos por encima del límite superior, ya que ningún paciente tiene una glucosa menor a 21.98. Estos registros se **conservaron**: una glucosa elevada puede corresponder a casos reales de diabetes, que podrían estar relacionados con el riesgo de derrame, por lo que eliminarlos implicaría perder información valiosa.

Codificación y limpieza final. Se eliminó la columna `id`, pues solo identifica al paciente y no aporta información predictiva. Las variables `gender`, `ever_married`, `work_type`, `Residence_type` y `smoking_status` se codificaron con One-Hot Encoding. El resultado se guardó en un DataFrame aparte (`df_encoded`), conservando el original con etiquetas de texto para las gráficas.

```
df = df.drop(columns=["id"])
cols_cat = ["gender", "ever_married", "work_type",
            "Residence_type", "smoking_status"]
df_encoded = pd.get_dummies(df, columns=cols_cat, dtype=int)
print(df_encoded.shape)
```

Listing 3: Eliminacion de id y codificacion One-Hot

El DataFrame codificado quedó con 22 columnas.

5.3. Análisis visual

Distribución de la variable objetivo. Se graficó la cantidad de pacientes con y sin derrame.

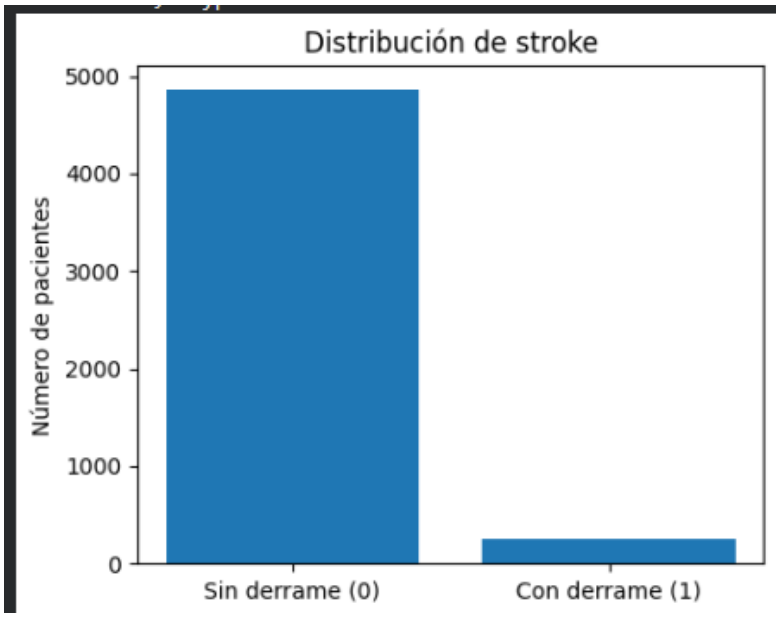


Figura 2: Distribución de la variable objetivo `stroke`

Histogramas de edad y glucosa. Se compararon las distribuciones de ambas variables entre los pacientes con y sin derrame, normalizadas con `density=True` para poder comparar su forma pese a la diferencia de tamaño entre grupos.

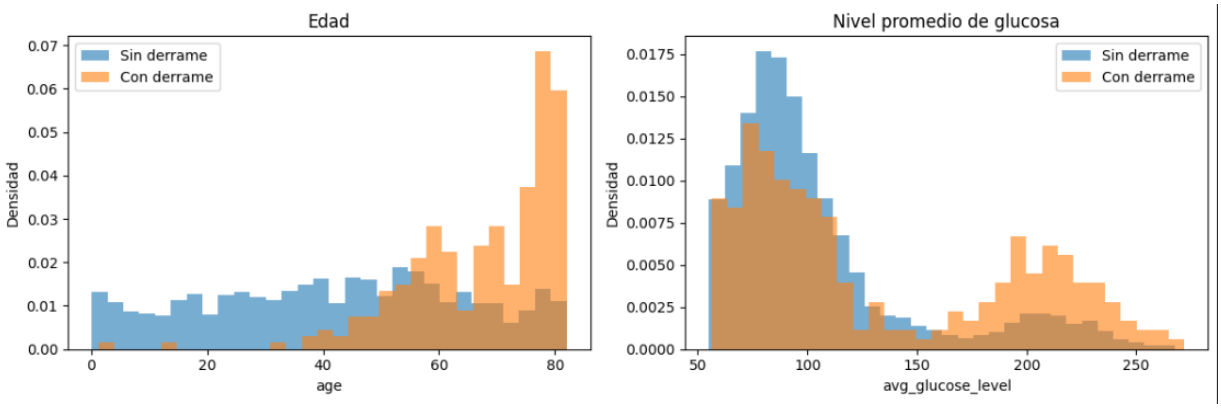


Figura 3: Histogramas de edad y nivel de glucosa según `stroke`

Diagrama de dispersión. Se relacionó la edad con la glucosa, diferenciando por color a los pacientes con y sin derrame.

```
sin = df[df["stroke"] == 0]
con = df[df["stroke"] == 1]
plt.scatter(sin["age"], sin["avg_glucose_level"], alpha=0.3, label="Sin derrame")
plt.scatter(con["age"], con["avg_glucose_level"], alpha=0.8, label="Con derrame")
plt.xlabel("Edad")
plt.ylabel("Glucosa")
plt.legend()
plt.show()
```

Listing 4: Diagrama de dispersion

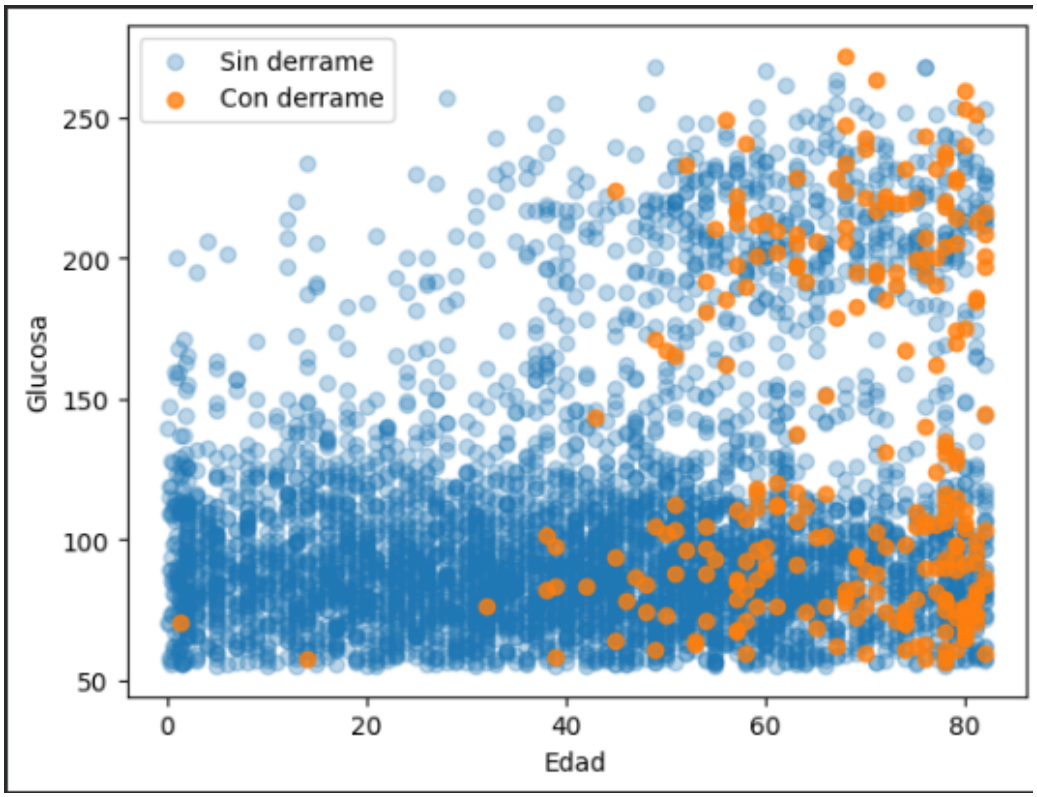


Figura 4: Relación entre edad y glucosa según `stroke`

6. Resultados y Análisis

Desbalance de clases. De los 5110 pacientes, 4861 (95.1 %) no tuvieron derrame y 249 (4.9 %) sí lo tuvieron. Esto implica que un modelo podría acertar cerca del 95 % prediciendo siempre "sin derrame" y aun así ser inútil para detectar los casos relevantes, por lo que la exactitud sería una métrica engañosa y habría que emplear otras (como *recall* o F1) o técnicas de balanceo.

Edad. En el histograma, los pacientes sin derrame se distribuyen de forma relativamente uniforme entre 0 y 80 años, mientras que los pacientes con derrame son prácticamente inexistentes antes de los 40 años, comienzan a aumentar desde los 50 y se concentran entre los 70 y 80 años.

Glucosa. Ambos grupos comparten una concentración principal entre 60 y 120. Sin embargo, los pacientes con derrame presentan además una segunda concentración alrededor de 200 a 250, mucho más marcada que en el grupo sin derrame; es decir, una fracción mayor del grupo con derrame tiene glucosa elevada. Aun así, en el diagrama de dispersión se aprecia que también hay muchos pacientes sin derrame con esos valores, y una parte importante de los pacientes con derrame tiene glucosa normal, por lo que la glucosa elevada no explica por sí sola los casos. Esto coincide con los valores atípicos detectados mediante el IQR.

Relación edad–glucosa. En el diagrama de dispersión, los puntos de pacientes con derrame se concentran principalmente entre los 60 y 80 años, con glucosa tanto normal como elevada. Casi no aparecen en edades jóvenes, sin importar su nivel de glucosa.

7. Conclusiones

A partir del análisis visual, se observa que el conjunto de datos está fuertemente desbalanceado, ya que solo alrededor del 5 % de los pacientes sufrió un derrame. Respecto a los factores de riesgo, la edad es el más determinante a simple vista: los casos de derrame se concentran en personas mayores de 60 años. El nivel de glucosa también parece relevante, pues un grupo de pacientes con derrame presenta valores muy elevados (superiores a 170), aunque otro grupo tiene valores normales, por lo que no explica por sí solo el riesgo. Estos hallazgos son descriptivos y no establecen relaciones de causa y efecto; sugieren que un modelo predictivo deberá considerar el desbalance de clases y la combinación de varias variables.

En cuanto al preprocesamiento, la imputación de `bmi` con la mediana, la conservación de los valores atípicos de glucosa y la codificación One-Hot dejaron el conjunto de datos listo para las siguientes etapas de modelado.

Referencias

[1] fedesoriano (2021). Stroke prediction dataset. Kaggle.

[2] Harris, C. R. et al. (2020). Array programming with NumPy. *Nature*, 585:357–362.

[3] Hunter, J. D. (2007). Matplotlib: A 2d graphics environment. *Computing in Science & Engineering*, 9(3):90–95.

[4] McKinney, W. (2010). Data structures for statistical computing in python. In *Proceedings of the 9th Python in Science Conference*, pages 56–61.

[5] Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.

Las imágenes utilizadas en este documento son propiedad de sus respectivos autores y se incluyen únicamente con fines académicos.